

Absamad Manturov

Python developer | AI evaluation | Agent reliability | Data automation

Moscow, Russia | Open to short paid pilots and technical collaboration

Telegram @Absamad_m

Email absamad.manturov@gmail.com

GitHub github.com/Absamad-dew

ПРОФИЛЬ

Создаю воспроизводимые проверки качества и надежности для LLM и tool-using agents, а также узкие Python-конвейеры обработки данных. Предпочитаю runnable proof, raw traces и заранее определенные критерии приемки вместо неподтвержденных обещаний.

ПУБЛИЧНЫЕ ДОКАЗАТЕЛЬСТВА

- GigaChat SDK PR #117 и #118 (open). Typed sync/async POST /filter/check, полный ContextVar/header guide; локально Ruff, strict мпы, 490 + 2 pytest.
- Yandex AI Studio SDK PR #235 (open). Backward-compatible per-attempt timeout внутри общего retry deadline; 233 локальных теста.
- ruagent-compat. 31 provider-neutral тест на JSON Schema, permissions, retry, idempotency, unknown outcomes и целостность state/effect; Linux/Windows CI.
- ru-agent-eval-kit. 22 synthetic security/reliability сценария x 3 повтора, raw traces и JUnit/JSON/Markdown; Ubuntu/Windows, Python 3.9/3.12.
- price-intelligence-demo. CSV/XLSX normalization, matching, confidence, review queue и audit trail; 7 тестов и независимая openpyxl проверка итоговой книги.

HARDNESS / SERVING EVIDENCE

Закрытый набор из 30 русскоязычных synthetic cases разделяет semantic score, strict contract и serving failures. Ornith 1.0 9B: 512 -> 768 tokens повысили overall 0.4527 -> 0.5481; conservative JSON-fence normalization дала 0.6198 без роста strict. Generic schema обеспечила parseability только через явный reasoning-channel adapter, но semantic score снизился до 0.5081. Это negative result, а не leaderboard claim.

ПЕРВЫЕ 48 ЧАСОВ ПИЛОТА

1 Зафиксировать score

10-30 примеров, acceptance metric, allowed data и среда без скрытых production effects.

3 Проверить минимальный patch

Budget, schema, adapter или gate меняются по одному; есть ablation и stop rule.

2 Снять baseline

Raw traces, версии модели/runtime, seed, latency/cost и failure taxonomy до любых исправлений.

4 Передать воспроизводимый результат

Tests, CI artifact, raw/normalized metrics, ограничения и следующий reversible step.

ПРОВЕРЯЕМЫЙ СТЕК

Python - pytest - async HTTP - JSON Schema
Quality - Ruff - strict мпы - CI matrices
Agent reliability - retries - idempotency -
permission gates - trace/state audit
Data - CSV/XLSX - openpyxl - normalization -
review queues
Delivery - Git/GitHub - JUnit/JSON/Markdown -
reproducible releases

КОРОТКИЕ ПЛАТНЫЕ ПИЛОТЫ

Agent reliability preflight

2-4 дня

15-30 client-owned cases на mock/staging:
schema, permission, retry, idempotency, injection;
raw traces и CI-ready report.

Serving-correctness audit

1-3 дня

Raw output, conservative normalization и
semantic score; token/sampling ablation, stop
criteria и negative results.

Price / data reconciliation

3-5 дней

2-3 обезличенных CSV/XLSX, acceptance
sample, confidence и manual review queue,
auditable Excel/CSV delivery.

ГРАНИЦЫ ДОКАЗАТЕЛЬСТВА

- Open PR не называется merged contribution.
- Synthetic demo не выдается за production case.
- Security testing - только в письменном scope.